

Case Study I: Primijenjena analiza podataka o biološkim sekvencama

Klasifikacija DNA sekvenci s k-merima (skup podataka o žabama)

Student: Demir Halilbašić

Ustanova: Internacionalna poslovno-informaciona akademija Tuzla

Predmet: Uvod u analizu podataka

GitHub repository: <https://github.com/demirhalilbasic/uuap-case-study-1>

Datum: 10.05.2026. godine

Etička izjava i ograničenje odgovornosti

Predstavljeni podaci preuzeti su sa NCBI (National Center for Biotechnology Information) platforme u FASTA formatu, koriste se isključivo u svrhu vježbe i primijenjene analize podataka. Sva autorska i vlasnička prava na genomske sekvence zadržava NCBI platforma. Ovaj projekat ne predstavlja biološko istraživanje, niti donosi autoritativne biološke zaključke. Rad obuhvata eksperimentisanje sa brojčanim podacima, prepoznavanje skrivenih obrazaca i statističku evaluaciju računarskih klasifikatora.

Za pisanje Python koda *lab_pipeline.py* i automatizovano generisanje grafika korištena je asistencija jezičkog AI modela Claude Opus 4.6.

Osnovna hipoteza

Polazna pretpostavka ovog istraživanja glasi: dvije sestrinske vrste (*Bombina bombina* i *Bombina variegata*) zbog visoke genetičke sličnosti trebaju formirati zajednički klaster u PCA prostoru, dok podaci za treću vrstu (*Rana temporaria*) koja pripada drugoj porodici, trebaju biti jasno odvojeni.

Potvrda ove pretpostavke dokazuje da računarski algoritmi mogu prepoznati genetsku srodnost i strukturne obrasce, bez potrebe za složenim biološkim poravnanjem sekvenci.

1. Uvod i odabir domene istraživanja

Analiza je bazirana na DNK fragmentima navedene tri vrste. One su primarno odabrane zbog svoje lokalne relevantnosti, obzirom da sve tri naseljavaju Balkan, dok su mukačice (rod Bombina) široko rasprostranjene i na području Bosne i Hercegovine.


Mukačice (*B. bombina* i *B. variegata*) u prirodi često formiraju tzv. hibridne zone i posjeduju visoko slične sekvence, čime predstavljaju izazov za preciznu računarsku klasifikaciju. Projekat koristi te podatke kao idealan poligon za testiranje mogućnosti mašinskog učenja u izdvajanju obrazaca iz sirovog teksta genoma.

2. Ekstrakcija značajki i procjena parametra K

U prvoj fazi analize, DNK sekvence podijeljene su na podnizove dužine k (k-mere). Testirano je postepeno povećanje dužine zadatih fragmenata ($k=3, 4, 5, 6$) kako bi se ispitala sposobnost modela da prepozna i klasifikuje vrste isključivo na osnovu učestalosti kratkih znakova.


Dužina fragmenta (k)	Broj ekstraktovanih značajki	Ostvarena tačnost
3	64	45%
4	256	70%
5	1024	85%
6	4004	95%

Tabelarni rezultati pokazuju direktnu vezu između broja dimenzija (značajki) i sposobnosti modela da uspješno razlikuje sekvence. Manje vrijednosti ($k=3$ i $k=4$) daju neprecizne predikcije zbog manjka konteksta i nedovoljne dužine isčitavanja, dok mjera $k=6$ donosi tačnost klasifikacije od 95%.



Grafikon 1: Kretanje tačnosti klasifikacije u funkciji k-mer parametra

Vizuelna validacija modela provedena je primjenom algoritma za analizu glavnih komponenti (PCA), čime je složeni visokodimenzionalni prostor reduciran na dvodimenzionalni pregled:




Grafikon 2: Dvodimenzionalna PCA distribucija podataka za k=4

Dok prethodni grafikon prikazuje visoku raspršenost i preklapanje podataka za $k=4$, naredna ilustracija pokazuje kako postepeno povećanje parametra k dovodi do jasnijeg razdvajanja klasa i formiranja prepoznatljivih grupa.

Napomena: Broj ekstrahiranih značajki za $k=6$ iznosi 4004, što odgovara broju jedinstvenih 6-mera koji se empirijski pojavljuju u analiziranim sekvencama, za razliku od teorijskog maksimuma od 4096.

Poređenje PCA vizualizacija za različite vrijednosti k




Grafikon 3: Promjena rezolucije klastera prilikom prelaska sa $k=3$ na $k=6$

Raspored podataka savršeno potvrđuje testiranu hipotezu. Vrsta *Rana temporaria* (zeleni klaster) se već pri najosnovnijim modelima jasno izdvaja u nezavisan prostor, što se savršeno poklapa s njenom biološkom pripadnošću drugoj porodici nasuprot muhačicama.


3. Klasifikacija u uslovima visoke sličnosti

Kako bi se dodatno testirala osjetljivost algoritma, *R. temporaria* je izostavljena. Model se tada fokusirao isključivo na prepoznavanje dvije sestrinske vrste koje karakteriše izuzetno visoka genetička bliskost.




Grafikon 4: PCA distribucija izolovano na sestrinske vrste

Performanse klasifikatora u ovom zadatku najbolje opisuju matrice konfuzije koje prikazuju stopu uspješnosti, odnosno broj pogrešno klasifikovanih instanci za posmatrani k parametar.



Grafikon 5: Matrica konfuzije sestrinskih vrsta pri $k=4$

Kao što matrica konfuzije ($k=4$) pokazuje, model ne može precizno razlikovati klase zbog nedostatka dubine informacija pa često tek nasumično nagađa i donosi veliki broj grešaka. Prelaskom na algoritam sa nivoom $k=6$ (matrica ispod) te greške se drastično smanjuju i algoritam lakše pronalazi različitosti.




Grafikon 6: Optimizovana matrica konfuzije pri $K=6$

Pri $k=4$, model bilježi tačnost od samo oko 50%, što se svodi na slučajan odabir. Uvođenjem potpunije pretrage na $k=6$, klasifikator uspijeva pronaći suptilne granice i podići tačnost pronalaženja vrsta na odličnih ~86%.


4. Komparativna analiza modela mašinskog učenja

Završni zadatak bio je uporediti različite primijenjene pristupe mašinskog učenja pri optimizovanom modelu ($k=6$). Testirani su modeli: Logistička regresija, Linearni SVM i Random Forest stablo odlučivanja.



Grafikon 7: Distribucija i performanse matrica po modelima

Uporedo gledajući prikaze matrica, uočićemo da kod stablastog modela (Random Forest) postoje najjača netačna očitavanja predviđanja. Stupčasti grafikon ispod donosi konačni pregled na kojem se jasnije uočava procenat uspješnosti u korist stabilnosti linearnih modela:



Grafikon 8: Komparacija konačnih metrika tačnosti testiranih algoritama

Linearni modeli (Logistička regresija i SVM) briljiraju sa stopom uspjeha od ~95%. Kompleksniji Random Forest algoritam gubi performanse i pada na 70% usljed prilagođavanja (overfittinga). Budući da model ima jako mali uzorak u odnosu na stvorenih hiljade varijabli pretrage, umjesto pronalaženja glavnog šablona, model počinje neefikasno „pamtiti“ nevažne sličnosti elemenata.

5. Zaključak

Predloženi podaci iz testnog izvođenja i pratećih obrada potvrdili su hipotezu u cjelosti.

Analizom k-mera obrađeni su podaci sirovih genoma, bez ulaženja u specifična biološka svojstva, gdje su prepoznate stabilne klase s visokom stopom tačnosti. Iako su razlike u frekventnom sastavu minimalne, matematički modeli su grupisali srodne vrste i u potpunosti izostavili vrstu koja im evolucijski ne pripada.

Na osnovu dobijenih rezultata, predlažem sljedeće pravce za buduća istraživanja:

Proširivanje skupa podataka većim brojem sekvenci po vrsti doprinijelo bi statističkoj robusnosti modela i smanjilo rizik od slučajnih odstupanja u rezultatima. Testiranje viših vrijednosti parametra k ($k=7$, $k=8$) moglo bi utvrditi postoji li gornja granica korisnosti ovog pristupa, odnosno tačka zasićenja gdje povećanje k više ne donosi napredak u tačnosti. Uvođenje cross-validacije umjesto jednostavne podjele na trening i testni skup pružilo bi pouzdaniju procjenu generalizacije modela. Analizu bi bilo zanimljivo proširiti na dodatne balkanske vrste vodozemaca kako bi se ispitalo može li isti pristup uspješno skalirati na složenije scenarije klasifikacije.

6. Reference

Bombina bombina: <https://www.ncbi.nlm.nih.gov/datasets/taxonomy/8345/> (Pristupljeno: 09.05.2026.)

Bombina variegata: <https://www.ncbi.nlm.nih.gov/datasets/taxonomy/8348/> (Pristupljeno: 09.05.2026.)

Rana temporaria: <https://www.ncbi.nlm.nih.gov/datasets/taxonomy/8407/> (Pristupljeno: 09.05.2026.)